

DAT 158 – Vin Kvalitet ML-Modell

Patrick Hundere, Mats Kristian Karstad, Håvard Andreas Nesheim Kvalsøren

Dato: 2. November 2025

Webapp: <https://mlassignment2-n49gzddebey88hzwj8sod9.streamlit.app/>

I dette prosjektet skal vi bygge en maskinlæringsbasert webapplikasjon som skal kunne predikere kvaliteten på vin (hvit og rød) basert på kjemiske målinger fra «Wine Quality»-datasettet (Cortez, Cerdeira, Almeida, Matos, & Reis, 2009). Målet er å lage en fullstendig ML-produkt-pipeline: dataforberedelse, modellering (Random Forest og Gradient Boosting), evaluere og deployment som en enkel webb-app (Streamlit). Rapporten følger livssyklusen fra problemdefinisjon til deployment.

Innholdsfortegnelse

DAT 158 – Vin Kvalitet ML-Modell.....	1
1. Problemet	2
1.1. Omfang.....	2
1.2. Metrikker.....	2
2. Data	2
2.1. Datatype og struktur	3
2.2. Datakilder og mengde	3
2.3. Label og fordeling	4
2.4. Databehandling.....	5
2.5. Etikk og personvern.....	5
2.6. Datapresentasjon til modell	5
3. Modellering.....	5
3.1. Prosess.....	6
3.2. Resultater	8
3.3. Observasjoner	8
4. Deployment	9
5. Referanser	9
6. Vedlegg (Manuelle tester og resultater av ulike hyperparameter).....	10

1. Problemet

1.1. Omfang

Oppgaven er å lage en web-basert løsning som tar inn de følgende 11 måleverdiene: «Fixed Acidity», «Volatile Acidety», «Citric Acidity», «Residual Sugar», «Chlorides», «Free Sulfur Dioxide», «Total Sulfur Dioxide», «Density», «pH», «Sulphates» og «Alcohol». Med disse måleverdiene ønsker vi å returnere en predikert kvalitetsskåre. Maskinlæring er et godt valg fordi kvalitetsskåren korrelerer med flere kjemiske målinger samtidig – et regressjonsproblem hvor mønstre i data kan utnyttes for å gi raske estimeringer til brukere.

Løsningen skal være en nettside hvor brukeren velger vintype (hvit eller rød), fyller inn de 11 måleverdiene og får tilbake en forventet kvalitet. Det finnes flere open-source eksempler på dette prosjektet på nettet. Vårt bidrag med dette prosjektet er ment til å slå sammen en sånn modell med brukervennlig web-grensesnitt. Dersom man skulle ønske å gjøre dette manuelt, ville man gjerne brukt vinsmakere, enkle regel for grenser av de ulike verdiene. En sånn løsning kunne bli benytta av vinprodusenter for å få raske estimeringer av kvaliteten på vin.

1.2. Metrikker

Vi bruker følgende metrikker for å estimere kvaliteten på modellen:

- Mean Squared Error (MSE) – hovedmål for regresjonsfeil
- R^2 (forklaringsgrad) – for å vise hvor mye variasjon modellen forklarer.

Lav MSE og høy R^2 betyr mer pålitelig prediksjoner

2. Data

Datasettet som brukes i dette prosjektet er Wine Quality Dataset (Cortez, Cerdeira, Almeida, Matos, & Reis, 2009), hentet fra UCI Machine Learning Repository. Datasettet består av to deler: ett for rødvin (winequality-red.csv) og ett for hvitvin (winequality-white.csv). Begge inneholder kjemiske målinger av portugisisk «Vinho Verde»-vin fra Nord-Portugal

2.1. Datatype og struktur

Datasettet er med flere variabler og består kun av numeriske verdier.

Hver rad representerer en enkelt vinprøve, mens kolonnene representerer mlinger av 11 ulike kjemiske egenskaper. Kvaliteten (quality) er gitt som en skår mellom 0 og 10 (typisk 3-9) basert på sensoriske vurderinger fra vinsmakere.

Variabel	Beskrivelse
fixed acidity	Konsentrasjon av ikke-flyktige syrer
volatile acidity	Konsentrasjon av flyktige syrer
citric acid	Mengde sitronsyre
residual sugar	Mengde gjenværende sukker etter fermentering
chlorides	Saltinnhold
free sulfur dioxide	Mengde fri svoveldioksid
total sulfar dioxide	Total mengde svoveldioksid
density	Tetthet, relatert til alkohol og sukkerinnhold
pH	Surhetsgrad
sulphates	Svovelforbindelser relatert til konservering og smak
alcohol	Alkoholinnhold (%)
Quality (heltall, label)	Sensorisk vurdering mellom 0 og 10

Datasettet har ingen manglende verdier, og alle attributter er kontinuerlige reelle tall.

2.2. Datakilder og mengde

- Hvitvin: 4898 observasjoner
- Rødvin: 1599 observasjoner

Data er offentlige tilgjengelig fra [UCI Machine Learning Repository](https://www.kaggle.com/ucimachinelearning)

Data ble hentet direkte fra denne kilden som .csv-filer og lagret i prosjektets mappe WineQualityData/.

2.3. Label og fordeling

Target-variabelen quality er skjevfordelt: de fleste vinene ligger i midtsjiktet (kvalitet 5-7), mens svær får har høy eller lav kvalitet

Kvalitet	Antall prøver for hvitvin	Antall prøver for rødvin
0	0	0
1	0	0
2	0	0
3	20	10
4	163	53
5	1457	681
6	2198	638
7	880	199
8	175	18
9	5	0
10	0	0

Dette innebærer at modellen kan ha en tendens til å predikere verdier nær gjennomsnittet ettersom ekstreme kvaliteter er underrepresentert

Kode for å telle de prøvene for ulike kvalitet:

```
import pandas as pd

df = pd.read_csv(r"./WineQualityData/winequality-red.csv", sep=';') #or white wine

quality_counts = df['quality'].value_counts().sort_index()

print("Number of samples per quality:")
print(quality_counts)
```

2.4. Databehandling

Før modellering ble følgende trinn utført:

1. Lesing og sammenslåing: Data for hvit og rød vin behandles separat, siden egenskapene kan ha ulik betydning for de to typene.
2. Rensing: Datasettet inneholder ingen manglende verdier, og gitt kilden (som en ml-repository) for datasettet ble ikke noen av radene fjernet.
3. Splitting: Data ble delt i 80% treningsdata og 20% testdata (eventuelt 85/15 i noen eksperimenter), med `random_state=42` for å være reproducerbare.

2.5. Etikk og personvern

Datasettet inneholder ingen persondata eller sensitive opplysninger. Alle variabler er tekniske målinger og vurderinger utført anonymt. Dermed er det ingen etiske utfordringer knyttet til bruken av dette datasettet.

2.6. Datapresentasjon til modell

Input til modellen representeres som en vektor med 11 numeriske verdier, i følgende rekkefølge:

["fixed acidity", "volatile acidity", "citric acid", "residual sugar", "chlorides", "free sulfur dioxide", "total sulfur dioxide", "density", "pH", "sulphates", "alcohol"]

Denne vektoren mates inn til modellen for å predikere en enkelt verdi `quality`, som deretter runders av og presenteres for brukeren på nettsiden

3. Modellering

(Gradient Boosting Regressor og Random Forest Regressor)

I dette prosjektet ble to ulike regresjonsmodeller brukt for å predikere vinkvaliteten basert på de 11 kjemiske målingene: Random Forest Regressor (RF) og Gradient Boosting Regressor (GB). Hver modell ble trent og evaluert separat for både rødvin og hvitvin.

3.1. Prosess

Modelleringen ble gjennomført i to faser

1. Manuell parameterjustering

Først ble egne treningsskript kjørt for hver kombinasjon av vintype og modell:

- rf_red_wine_trainer.py
- rf_white_wine_trainer.py
- gb_red_wine_trainer.py
- gb_white_wine_trainer.py

Her ble hyperparameteren satt manuelt i koden (som antall trær, laringsrate, dybde osv.) for å få en baseline og forstå hvordan parameterne påvirket resultatene

For eksempel for Random Forest ble parametrene typisk:

```
model = RandomForestRegressor(  
    n_estimators=100,  
    min_samples_split=3,  
    min_samples_leaf=1,  
    random_state=42  
)
```

Og for Gradient Boosting:

```
model = GradientBoostingRegressor(  
    n_estimators=200,  
    learning_rate=0.2,  
    max_depth=7,  
    min_samples_split=5,  
    min_samples_leaf=1,  
    random_state=42  
)
```

Evalueringen ble gjort både på treningsdata med MSE (Mean Squared Error) og R^2 (forklaringsgrad). Denne fasen gat et første inntrykk av modellens ytelse og risiko for overtilpassing.

2. Systematisk hyperparameter-søk (bestloop)

Etter de manuelle eksperimentene ble fire nye skrip laget:

- rf_red_wine_trainer_bestloop.py
- rf_white_wine_trainer_bestloop.py
- gb_red_wine_trainer_bestloop.py
- gb_white_wine_trainer_bestloop.py

Disse kjørte et grid search-lignende loopgjennom kombinasjoner av hyperparametere for å finne den beste kombinasjonen basert på test- R^2 .

Eksempel for Random Forest:

```
param_grid = {  
    'n_estimators': [100, 200, 300],  
    'min_samples_split': [2, 3, 4, 5, 6, 10],  
    'min_samples_leaf': [1, 2, 3, 4, 5]  
}
```

Hver kombinasjon ble evaluert, og den modellen med høyest R^2 på testsettet ble lagret.

For Gradient Boosting ble større grid testet:

```
param_grid = {  
    'n_estimators': [100, 200, 300, 400],  
    'learning_rate': [0.05, 0.1, 0.2],  
    'max_depth': [2, 3, 4, 5, 6, 7],  
    'min_samples_split': [2, 3, 4, 5, 6],  
    'min_samples_leaf': [1, 2, 3, 4]  
}
```

..

Etter gjennomføring ble de beste modellene lagret som .pkl-filer i models/ mappen.

3.2. Resultater

Modell	Vintype	Beste parameter	Test R^2	Test MSE	Kommentar
Random Forest	Hvitvin	n_estimators=300 min_samples_split=3 min_samples_leaf=1	0.555	0.345	Robust, god generalisering
Gradient Boosting	Hvitvin	n_estimators=400 learning_rate=0.1 max_depth=7 min_samples_split=6 min_samples_leaf=2	0.586	0.332	Best ytelse totalt
Random Forest	Rødvin	n_estimators=100 min_samples_split=3 min_samples_leaf=1	0.546	0.297	Litt bedre generalisering enn GB
Gradient Boosting	Rødvin	n_estimators=200 learning_rate=0.1 max_depth=7 min_samples_split=5 min_samples_leaf=1	0.531	0.313	Litt overtilpasset, men stabil

Se tabellen med noen av de manuelle inntastinga av hyperparameter under [Vedlegg \(Manuelle tester og resultater av ulike hyperparameter\)](#)

3.3. Observasjoner

- Random Forest viste generelt høy stabilitet og god generalisering
- Gradient Boosting kunne oppnå høyere R^2 på trening, men noe lavere på test som viser til overfitting
- Forskjellen mellom rød og hvit vin skyldes trolig at hvitvinsdatasettet er større og har jevnere fordeling
- Ekstreme inngangsverdier (som veldig høye syrer eller sukker) gir urealistisk predikasjoner, noe som viser at modellen ikke håndterer uteliggere utenfor treningsområdet godt
- Kvaliteten på vin er en subjektiv metrikk og flere element enn de 11 features-ane kan ha en effekt på kvaliteten

4. Deployment

4.1. implementasjon

Modellen ble lagt ut som en Streamlit-applikasjon tilgjengelig på

<https://mlassignment2-n49gzddebey88hzwj8sod9.streamlit.app/>

Struktur

- Frontend: streamlit-grenesnitt der brukeren velger vintype (rød/hvit) og fyller inn 11 måleverdier
- Backend: lastet inn .pkl-fil av valgt modell. Når brukeren trykker «Beregn» og verdiene er sendt gjennom wine_quality_predictor.py for å bregne kvaliteten
- Output: Predikert vinkvalitet vises på skjermen (usannsynlig å få under 4 eller over 8 med dette datasettet)

4.2. Teknisk arkitektur

- models/ - lagrer trenede modeller (.pkl)
- WineQualityData/ - datasett
- app.py – Streamlit hovedfil
- trainingscripts/ - treningsskript for ulike modeller
- wine_quality_predictor.py – funksjoner for å predikere kvalitet av enten hvitvin eller rødvin

4.3. Monitorering og vedlikehold

Applikasjonen er et ferdig prototype-produkt. Videre utvikling kunne inkludere:

- Logging av brukerinput
- Feilhåndtering av ugyldige verdier (uteliggere)
- Mulighet for batch-predikasjoner

4.4. Forbedringsmuligheter

- Bedre egnet for mer ekstreme verdier som for øyeblikket ikke får lavere kvalitetsskåre enn
- Prøve ut andre modeller som muligens er bedre

5. Referanser

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009, Oktober 6). *Wine Quality*. Retrieved Oktober 28, 2025, from UC Irvine Machine Learning Repository: <https://archive.ics.uci.edu/dataset/186/wine+quality>

6. Vedlegg (Manuelle tester og resultater av ulike hyperparameter)

Modell	Vintype	Test størrelse	N_ estimators	Min_samples_ split	Min_samples_ leaf	Learning rate	Max_ depth	Test MSE	Test R ²
RF	Hvitvin	0.2	100	2	1			0.348	0.551
RF	Hvitvin	0.2	200	2	1			0.345	0.554
RF	Hvitvin	0.15	200	2	1			0.361	0.559
RF	Hvitvin	0.15	200	3	1			0.361	0.558
GB	Hvitvin	0.2	200	2	1	0.1	3	0.445	0.426
GB	Hvitvin	0.1	300	2	4	0.2	5	0.373	0.535
RF	Rødvin	0.2	100	2	1			0.306	0.532
RF	Rødvin	0.2	200	2	1			0.306	0.532
RF	Rødvin	0.2	200	3	1			0.303	0.536
RF	Rødvin	0.2	100	3	1			0.297	0.546
GB	Rødvin	0.2	200	2	4	0.2	5	0.344	0.473
GB	Rødvin	0.2	100	2	4	0.2	5	0.340	0.480